

9주차 Machine Learning

1. Search-based Optimization Tech. for Real-life Problems
2. Reasoning, Inference and Knowledge Representation
3. Machine Learning/Pattern Recognition/ Data Science(Mining)

Classification (Supervised Learning)	분류	지도학습
Clustering (Unsupervised Learning)	군집화	비지도학습

Machine Learning이란?

Machine Learning 기술은 이미 발전하고 있음

1990년대 이후 digital data에 대한 획득과 스토리지 기술이 발전함. -> 큰 DB의 발전함.

implicit(암묵적)이고, 이전에는 알지 못했으며, 잠재적으로 유용한 정보를 추출하는 것.

알고리즘은 **불완전한 대용량 데이터**를 다룰 수 있어야 하며, 정확하지는 않지만 **유용한 패턴**을 추출해야 함.

목적: 우리는 데이터베이스(클라우드)를 자동으로 살살이 뒤져서 패턴을 찾아내는 알고리즘을 구축하고자 한다.
만약 strong pattern(강한 패턴)이 발견된다면, 이는 미래에 대한 정확한 예측을 수행할 수 있도록 일반화될 것이다.
-> real world에 대해서 prediction을 할 수 있다.

인식, 분류 => 인간의 삶의 주요한 기술 "선택"의 순간

Machine Learning = Pattern recognition(인식) = Classification

인류의 삶이 시작된 이래로 우리는 데이터 속에서 패턴을 찾아왔다.

e.g. 애플 페이나 카카오 페이의 관리자들은 사용자들에게 개인화된 서비스를 제공하기 위해 그들의 '소비 패턴'을 찾아내기를 원함.

물고기 그림


Q) 이 물고기의 이름이 뭘까?

100마리의 물고기가 있고 물고기의 길이(length)를 측정해 보자!

fish: $x = [\text{length}]$

-> 우리의 알고리즘은 새로운 fish의 길이를 측정하고, 이름(label)을 예측한다!

$x = [10\text{cm}]$: vector notation




23cm인 새로운 물고기가 들어왔는데... $x=23\text{cm}$ 이다. 연어일까? 농어일까?

이것이 기본적인 classification, prediction. 흔히 정확하지 않고, 만족스럽지 않다. -> 틀릴수도 있음!

그렇다면 방금 시도한 '길이'를 재는 것이 아닌 밝기(brightness)를 측정해보자!


② 밝기 $Lightness$ $x = [x \text{ } lx]$



Q: New fish $x = 7Lx \rightarrow ?$ Bass
 $x = 3Lx \rightarrow$ 연어.

밝기로 했더니, 오류인 부분이 있기는 하나, 많지 않네! $\rightarrow$ 길이보다 밝기라는 특징이 더 정확하구나!

$\rightarrow$ 그럼 이번에는 길이와 밝기를 **vector**로 나타내보자!



여기서 알 수 있는 것

1. 각 물고기는 2차원 XY좌표에서 하나의 점(vector)으로 표현된다.
2. 모든 대상은 좌표공간(coord. space)에서 N-dimentional vector로 표현된다.

$\rightarrow$ 세상은 **Matrix**로 표현된다!

"The World is represented as **Matrix**."

$$\begin{matrix} X_1 = \begin{bmatrix} 10\text{cm} \\ 5Lx \end{bmatrix} \\ X_2 = \begin{bmatrix} 20\text{cm} \\ 3Lx \end{bmatrix} \\ X_3 = \begin{bmatrix} 10 \\ 10 \end{bmatrix} \end{matrix} \Rightarrow \begin{bmatrix} 10 & 5 & x_1 \\ 20 & 3 & x_2 \\ 10 & 10 & \end{bmatrix}$$


목적 : **Loss function** $\rightarrow$ Error minimization

인공지능 모델이 달성해야 하는 최종 목표를 의미.

두 그룹을 효과적으로 분리하는 직선을 찾는 것

고등학교 수준의 간단한 수학을 사용하여 어떻게 line(선형방정식)을 찾을 것인가?

농어 점들의 평균, 연어 점들의 평균을 찾고, 두 선을 이은 다음, 중점의 법선 벡터가 line이다!



Machine Learning(Supervised Learning 감독 지도)

- 원래의 raw data를 가지고 패턴의 카테고리에 기초한 action

우리는 패턴을 recognize하고 predict하는 algorithm(또는 agent)를 만들어야 한다!

e.g. 어떻게 텍스트를 분류할까? 언어 vs 농어, 웹문서, SNS...

-> opinion mining, sentiment analysis...

1 - $\Rightarrow$ Vector
 $\frac{\text{text}}{(\text{카테고리})}$ Facebook $\Rightarrow X = \begin{bmatrix} \text{단어} \\ \text{단어} \\ \text{단어} \end{bmatrix}$

Pattern Matrix

: n x d 패턴/데이터 행렬

n : 데이터의 개수

d : 각 데이터가 가진 특징의 개수

각각의 패턴은 하나의 feature vector로 표현된다.

lable(정답)이 지정된 training patter이 주어지면, 클래스 그룹은 이미(priori) 알려진 상태이다.

training pattern matrix는 파일이나 DB, 클라우드에 저장되어 있다.

-> 우리는 이미 알려진 그룹들 안에서 새로운 데이터를 분류하기 위한 알고리즘을 구축한다.

n개의 pattern : objects, observations, vectors, records...

d개의 features : attribues, filed, dimension...

training Data 훈련 (Data) $\uparrow$

n x d "Pattern Matrix"

Variables (field, dimension)

Fish	Light	Length	Weight	"Label"
f ₁	10	70	6	연어
f ₂	10	75	8	연어
f ₃	29	51	9	bass
f ₄	36	49	8	bass

'n' patterns (given)
 objects, observations, ~~data~~ Vectors, Records

"Label" : 정답. 반드시 있어야 함!

-> 이를 바탕으로 training data 훈련

Train(ing) Data vs. Test Data

# data	# features
data ₁ x 1	f ₁ f ₂ ... f _d
" 2	"
" :	"
" 100	"
" n	"

Training Data vs Test Data

Training Data : 알고리즘을 학습시키기 위해 제공되는 데이터. 반드시 Label(답)이 포함되어 있어야 함.

Test Data : 개발한 알고리즘이 학습이 잘 되었는지 성능과 정확도를 평가하기 위해 주어지는 데이터.


Training Data와 비슷하지만, Class Label만 쏙 빠져있는 형태.

e.g. 암이 있는지, 그게 양성인지 음성인지

판별하는 머신러닝 알고리즘을 개발해보자!

train Data vs. Test Data (비교)

feature	label
100 patient	Cancer
301	normal
165cm	
50kg	
120	
200	



Accuracy : 예측 알고리즘의 performance를 평가하는 것

1. (simple) Accuracy : $\frac{TP+TN}{TP+TN+FP+FN}$

① (simple) accuracy :

		Truth (Gold standard...)	
		positive	Negative
prediction result (Alg)	positive	True positive	False positive
	Negative	false negative	True Negative

e.g)

		pos Cancer	Neg Normal
(true)	Cancer (pos)	TP	FP
	Normal (Neg)	FN	TN

- True Positive (TP): 정답이 Positive인데 알고리즘도 Positive라고 맞게 예측한 경우입니다.
- True Negative (TN): 정답이 Negative인데 알고리즘도 Negative라고 맞게 예측한 경우입니다.
- False Positive (FP): 정답은 Negative인데 알고리즘이 Positive라고 잘못 예측한 경우입니다.
- False Negative (FN): 정답은 Positive인데 알고리즘이 Negative라고 잘못 예측한 경우입니다.

Bayes' Theorm 베이즈 정리

개념적으로 prediction algorithm은 두 개의 class(분류)를 분리하는 선을 찾으려고 노력함.

line(선) : optimal hyperplane 최적 초평면

n차원에서 두 클래스 간 간극을 최대화하여 완벽하게 분리하는 optimal hyperplane을 찾는 것을 목적으로 함

종류, 접근/전략 :

- Parametric statistical algorithms: mean, deviation 확률적, 통계적 <-> Non-parametric algorithms
- Linear discriminant algorithm 선형적 <-> Non-linear algorithms
- Rule-based algorithms
- Regression-based algorithms

2가지 간단한 classifier

1. Bayesian Classification 베이즈 분류 알고리즘
2. Nearest Algorithm 최근접 이웃 알고리즘

Bayesian Classification

Q : 왜 이 알고리즘이 Statistical한 알고리즘일까? 왜 통계적 접근법을 사용할까?

A : 주어진 분류 문제가 **확률적으로 표현**될 수 있고, 분류에 필요한 **관련 확률 정보가 알려져 있다고 가정**한다.

-> 주어진 패턴의 class label을 결정할 **확률**을 계산할 수 있다.

e.g. 연어일 확률, 농어일 확률, 암일 확률, 지문(인증) 확률...

Q : 길이가 10cm 인 새로운 물고기 X가 주어졌을 때, 연어인지 농어인지 **확률 계산**만으로 맞춰보세요

-> X가 주어졌을 때 X가 어떤 클래스일지 확률을 구해보자

1. A가 발생했을 때 B의 확률(10cm일 때 농어일 확률) $P(B|A) = \frac{P(A \cap B)}{P(A)}$

2. ∩ 교집합 intersection 기호를 없애기 위해 Bayes' Theorm을 유도한다.

A와 B가 동시에 일어날 확률(교집합)은 순서를 바꿔서 두 가지 방식으로 표현할 수 있다.

$$P(A \cap B) = P(B|A)P(A) \quad \text{와} \quad P(A \cap B) = P(A|B)P(B)$$

두 식의 결과가 같으므로 양 변을 $P(A)$ 로 나누면, 마침내 Bayes' Theorem이 된다!

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)}$$

3. 물고기 문제에 대입해보면...

$$P(\text{Salmon}|x) = \frac{P(x|\text{Salmon})P(\text{Salmon})}{P(x)}$$

$$P(\text{Bass}|x) = \frac{P(x|\text{Bass})P(\text{Bass})}{P(x)}$$

여기서 분모 $P(x)$ 는 계산이 불가능하다.

왜냐하면 전 지구상 물고기 중 10cm일 확률 계산이 불가능하기 때문

다행히도 연어일 확률과 농어일 확률을 구하는 두 수식에서 분모가 $P(x)$ 로 동일하기 때문에 계산할 필요 없음.

□ ○ □ □